

Прогнозирование цен на продукты в супермаркетах



Пономарёва Вероника
Team Lead

Даирбеков Жоомарт
Data Analyst

Залимов Мухаммадазиз
ML Engineer

Думанаева Элина
Researcher

Толкунов Адилет
Presenter

Введение и **контекст** исследования

**В Бишкеке высокая конкуренция между
супермаркетами**

Цены зависят от многих факторов

Важно понять:

Можно ли
предсказать
цену товара?



Какие факторы
влияют
сильнее всего?




Какие модели
машинного
обучения дают
лучший
результат?



Распределение цен ↗

- 80 % товаров находятся в диапазоне до 150 сомов;
- оставшиеся данные (до 800 сомов) формируют мясные и сырны изделия, а также чай и кофе




Межмагазинные различия (Globus vs Narodny)

Средние цены по категориям различаются умеренно:

- Мясо и сыры - дороже в Globus (примерно +20 %)
- Бакалея, молочные и хлебобулочные - различия в пределах $\pm 10\text{-}15\%$

Межсетевые различия не носят системного характера, рынок унифицирован по основным категориям, что свидетельствует о зрелости конкурентной среды



Общая средняя цена
Globus = 118.6 сом

Общая средняя цена
Narodny = 99.0 сом

География происхождения и ценовые различия

Средние цены по странам
показали неожиданную
закономерность:

Гипотеза о том, что “импортное =
дороже”, не подтвердилась. Более
того, отечественные товары
оказались самыми дорогими.


Страна	Средняя цена
Кыргызстан	132.7
Казахстан	94.9
Россия	93.0
Украина	81.1
Италия	57.8

Влияние отдельных признаков ↗

Рейтинговый анализ важности признаков (по результатам **Ridge Regression** и **Random Forest**):

Рынок демонстрирует функциональное ценообразование: конечная цена определяется объективными свойствами - вес, тип продукта, размер упаковки, а не символическими, вроде страны происхождения или бренда

(Feature Importance)




Обучающая и тестовая точность модели почти совпадают ($R^2 \approx 0.99$ и $0.97-0.98$), что говорит об отсутствии переобучения.

Модель не просто запомнила данные, а выявила реальные закономерности между характеристиками товара и его ценой.

Также результаты показывают, что при добавлении новых данных и других супермаркетов качество прогнозов может стать ещё выше.

Learning Curve



Поведение моделей и метрики


Все модели показали высокие значения $R^2 > 0.96$, что говорит о том, что характеристики товара практически полностью объясняют его цену. Лучший баланс стабильности и точности достигает Ridge Regression - благодаря регуляризации она снижает влияние мультиколлинеарности (частичной взаимосвязанности признаков)

Модель	MAE (сом)	RMSE (сом)	R^2	CV R^2 mean
Linear Regression	11.11	22.73	0.975	0.961
Ridge Regression	10.71	21.41	0.978	0.971
Random Forest	10.71	27.14	0.964	0.980
Gradient Boosting	9.41	26.41	0.966	0.987

Ошибки:

- MAE примерно 10 сомов - в среднем модель ошибается на сумму не больше стоимости упаковки хлеба
- RMSE примерно 21 сом - демонстрирует невысокие амплитудные ошибки лишь для дорогих товаров.

График «Predicted vs Actual Prices»



Проект показывает, что цены на товары в супермаркетах Бишкека можно точно предсказывать с помощью машинного обучения.

Главными факторами цены являются категория товара, вес и цена за 100 граммов. Бренд и страна происхождения влияют значительно меньше.

Лучшая модель – Ridge Regression ($R^2 \approx 0.98$), что подтверждает высокую точность прогнозирования.

Исследование также показало, что рынок Бишкека является конкурентным и сбалансированным.

Общие итоги исследования

- Ответ на вопрос проекта: Да, цену товара в супермаркетах Бишкека можно предсказать с высокой достоверностью (R^2 примерно 0.98)
- Главные факторы: Базовая цена, категория, вес и нормализованная стоимость (price_per_100g)
- Неопределяющие факторы: Страна, бренд, тип упаковки
- Качество модели: Ridge Regression - лучшее соотношение точности и устойчивости, MAE примерно 10 сомов.
- Классификация: Random Forest Classifier почти без ошибок определяет ценовой сегмент
- Вывод для практики: Модель может использоваться для прогнозирования новых цен, проверки корректности установленных, определения целевых ценовых диапазонов для новых товаров и оптимизации промополитики

**Спасибо
за
ВНИМАНИЕ**

