

Predicting Product Prices in Supermarkets

Введение и контекст исследования

Рынок продовольственных товаров в городах Центральной Азии, включая Бишкек, отличается высокой конкуренцией и умеренной ценовой чувствительностью потребителей. Для ритейлеров и аналитиков актуальна задача - понимать, какие характеристики продукта формируют его цену и насколько она предсказуема исходя из объективных признаков, таких как категория, вес, бренд, страна происхождения или формат магазина

Проект направлен на ответ на исследовательский вопрос:

- Можно ли предсказать цену товара в бишкекских супермаркетах по его характеристикам?
- И если да, то какие факторы оказывают наибольшее влияние на ценообразование?

Исследование сочетает прикладной анализ с элементами рыночной диагностики, выявление закономерностей в формировании потребительских цен и определение степени унифицированности ценообразования в разных торговых сетях

Анализ собранных данных

1. Структура выборки

Собрано около 400 наблюдений по товарам из сетей Globus и Narodny - двух крупных супермаркетов г. Бишкек. Включены различные товарные категории: бакалея, кондитерские изделия, крупы, масло, молочные продукты, мясо, напитки, овощи-фрукты, сыры, хлебобулочные изделия, чай и кофе, яйца

Средние цены в выборке варьируются от 10 до 800 сомов, что охватывает практически весь потребительский диапазон - от базовых продуктов до премиальных

2. Распределение цен



Гистограмма распределения показывает чёткую асимметрию:

- 80 % товаров находятся в диапазоне до 150 сомов;
- оставшиеся данные (до 800 сомов) формируют мясные и сырные изделия, а также чай и кофе

Такая логарифмически-нормальная форма распределения характерна для ценовых рядов продуктов, большинство товаров массового спроса позиционируются в нижнем ценовом сегменте, тогда как несколько категорий создают длинный хвост премиальных цен

Гипотеза 1:

Основная часть продуктового рынка в Бишкеке сосредоточена в бюджетно-среднем сегменте, и только ограниченное число категорий относится к премиуму. Это соответствует структуре покупательной способности населения и устойчивым поведенческим паттернам регионального ритейла

Интерпретация


Когда мы строим график распределения цен, становится заметно, что подавляющее большинство товаров стоит дешево - примерно до 150 сомов и лишь небольшое количество достигает высоких значений, до 700 или 800 сомов. На визуализации графика такая форма называется логарифмически-нормальной (логнормальное распределение) и характерна для рынков повседневного потребления, где большая часть ассортимента принадлежит к недорогим категориям, а дорогие позиции встречаются редко. Проще говоря, значительная часть продуктового рынка в Бишкеке сосредоточена в бюджетно-среднем сегменте - это хлеб, крупы, бакалея, молочные и кондитерские изделия, которые покупаются ежедневно и имеют сравнительно низкую стоимость. К премиум-категориям можно отнести мясо, сыры и кофе, их гораздо меньше, и именно они формируют этот дорогой хвост (справа значения)

Такое распределение объясняется социально-экономическими условиями. У большинства горожан средний доход не предполагает регулярные траты на дорогие импортные продукты, поэтому покупатели предпочитают товары первой необходимости, где соотношение цены и насыщаемости максимально выгодно. Супермаркеты подстраиваются под этот спрос, они стараются обеспечить широкий выбор недорогих брендов и фасовок, которые удовлетворяют массового потребителя, и лишь в меньшей степени предлагают премиальные варианты, рассчитанные на узкий круг клиентов. Это создает четкое смещение товарной структуры в сторону дешевых продуктовых сегментов и объясняет, почему кривая распределения цен имеет столь выраженный перекося

Из этого можно сделать вывод, что рынок Бишкека организован рационально и устойчиво, он отражает реальные привычки и возможности покупателей. Бюджетно-средний уровень составляет основу розничных продаж, поскольку именно он обеспечивает стабильный оборот и массовый спрос. Можно предположить, что доля премиальных продуктов останется невелика до тех пор, пока реальные доходы горожан не вырастут заметно. Таким образом, распределение цен уже само по себе несет важную экономическую информацию, оно показывает структуру потребления, уровень благосостояния и

приоритеты покупателей, демонстрируя, что бишкекский рынок это рынок массового потребления

Межмагазинные различия (Globus vs Narodny)



1. Средние значения

Средние цены по категориям различаются умеренно:

- Мясо и сыры - дороже в Globus (примерно +20 %)
- Бакалея, молочные и хлебобулочные - различия в пределах +- 10–15 %
- Общая средняя цена Globus = 118.6 сом, Narodny = 99.0 сом

Расчет t-критерия ($t = 1.885$; $p =$ примерно 0.060) показывает различие на границе статистической значимости, но недостаточное для вывода о принципиальном расхождении

Ценообразование между сетями практически сбалансировано. Разница в уровнях цен объясняется скорее разным ассортиментом, чем политикой ценообразования. В Globus, вероятно, выше доля

фасованных и брендированных продуктов, тогда как Narodny продает больше товаров под private label или масс-брендов

Гипотеза 2:

Межсетевые различия не носят системного характера, рынок унифицирован по основным категориям, что свидетельствует о зрелости конкурентной среды

Интерпретация

Если рассмотреть цены в двух сетях Globus и Narodny, то можно заметить, что в целом они довольно близки, хотя есть небольшие различия. Анализ средних цен показывает, что в магазинах Globus продукты немного дороже. Например, мясо и сыры там стоят примерно на двадцать процентов больше, чем в Narodny. Некоторые категории вроде бакалеи, молочных продуктов или хлебобулочных показывают разницу около 10-15%, что считается умеренным разбросом. Когда все товары объединены, средняя цена покупки в Globus выходит около 118,6 сомов, тогда как в Narodny - около 99 сомов. Разница видна, но не слишком велика.

Чтобы понять, является ли эта разница статистически значимой, применялся t-тест - стандартный метод, с помощью которого проверяется, различаются ли средние значения в выборках действительно или это просто случайное отклонение. Полученное значение p-value примерно 0.06 означает, что вероятность того, что разница обусловлена простой случайностью, довольно велика (больше допустимого порога 0,05). Иными словами, разница между ценами в этих магазинах не считается статистически значимой. Мы можем сказать, что формально цены примерно одинаковые, хотя в практическом восприятии Globus выглядит чуть дороже

Здесь важно понимать, почему такая разница вообще есть. Сам по себе магазин не обязан быть дороже - скорее всего, дело не в политике ценообразования, а в структуре ассортимента. В Globus чаще можно встретить фасованные продукты, брендированные упаковки, импортные позиции или более качественные товары среднего уровня. У Narodny ассортимент немного другой - в нём больше массовых брендов и собственных торговых марок (private label), которые всегда дешевле, потому что магазину не нужно платить за раскрученное имя производителя. Поэтому средняя цена


по товарам в этой сети оказывается немного ниже, но это не означает, что продукция в целом хуже - просто она позиционируется как более повседневная и доступная

Эти данные позволяют сделать вывод, что ценообразование в бишкекских супермаркетах довольно унифицировано. Нет признаков, что одна сеть ведет себя как “премиальная”, а другая как дискаунтер. Обе оперируют в схожих ценовых условиях и конкурируют за одного и того же покупателя. Такое сходство говорит о зрелости рынка, сетям приходится ориентироваться на привычки потребителей и на уровень их доходов, поэтому они вынуждены удерживать цены в похожем диапазоне

Иными словами, мы наблюдаем устойчивую и конкурентную среду, где различия между магазинами объясняются не стратегией наценки, а особенностями ассортимента. На практике это означает, что покупатель может выбрать любой из супермаркетов, не ожидая ощутимой разницы в ценах на базовые товары. Это подтверждает, что на бишкекском рынке сформировалась равновесная ценовая структура, основные категории продаются примерно по одинаковым ценам, что снижает возможности для ценовых колебаний и указывает на зрелость и прозрачность конкурентной среды

География происхождения и ценовые различия

Средние цены по странам показали неожиданную закономерность:



Страна	Средняя цена
Кыргызстан	132.7
Казахстан	94.9
Россия	93.0
Украина	81.1
Италия	57.8

Гипотеза о том, что “импортное = дороже”, не подтвердилась. Более того, отечественные товары оказались самыми дорогими.

Гипотеза 3:

Высокие цены на местные товары связаны с их категориальной структурой: Кыргызстан производит значительную часть мясной и

молочной продукции - это дорогие категории по определению. Импортные же товары преимущественно относятся к бакалее, напиткам и сладостям - сегментам дешевого массового производства. Такое поведение данных подчеркивает, что "страна происхождения" не является универсальным детерминантом цены, определяющим остаётся тип продукта

Интерпретация:

Когда мы проанализировали средние цены товаров по странам происхождения, результаты оказались довольно неожиданными. Казалось бы, логично ожидать, что импортные товары - особенно из Европы - должны стоить дороже из-за транспортировки, таможенных сборов и брендов. Однако данные показали противоположное, самые дорогие продукты производятся не за границей, а внутри Кыргызстана. Средняя цена кыргызских товаров - примерно 132,7 сомов, в то время как у казахстанских - 94,9, российских - 93, украинских - 81, а итальянские, неожиданно, оказались самыми дешевыми - всего 57,8 сомов. Это сразу наводит на мысль, что само происхождение товара не определяет его цену. Здесь большую роль играет не страна, а тип продукта, который она производит. Кыргызстан выпускает много мясной и молочной продукции - это продукты, которые по своей природе дороже из-за высокой себестоимости: животноводство требует больше затрат, а срок хранения таких товаров короткий. Поэтому даже без больших наценок эти категории остаются дороже других

Импортные же товары из Украины, России, Италии чаще относятся к другим группам, например, это макароны, крупы, консервы, сладости или напитки. Все они относятся к массовому производству, и за счёт больших объёмов поставок и низкой себестоимости их цена оказывается ниже. Другими словами, дешевизна импортных товаров объясняется не тем, что они хуже, а тем, что они попадают в менее дорогие категории

Получается, что гипотеза "импорт дороже, чем местное" не работает. Наоборот, в Кыргызстане местные товары зачастую самые дорогие, потому что страна производит в основном продукты высокой пищевой ценности - мясо, молоко, сыр, масло. В то же время импорт идет из стран, где промышленное производство продуктов


поставлено на поток, и повышенные логистические издержки нивелируются экономией масштаба

Это важно, потому что разрушает распространенный стереотип: цена не всегда растёт из-за статуса импортного происхождения. Здесь важно учитывать именно категорию товара и его структуру производства. Для молока, мяса и сыра главным фактором цены является не страна поставки, а сложность изготовления, необходимость охлаждения и короткий срок хранения. Для круп, макарон и напитков главным становится объем производства и длительное хранение, что снижает цену.

Иными словами, страна происхождения сама по себе не формирует цену. Определяющим фактором остаётся тип продукта и его роль на рынке. Кыргызстан, как производитель свежих, натуральных и скоропортящихся изделий, демонстрирует более высокие средние цены, в то время как импорт обеспечен товарами повседневного массового спроса. Таким образом, рынок демонстрирует не зависимость от географии происхождения, а зависимость от категориальной структуры производства, то, что и где производят, напрямую влияет на ценовой уровень, а не национальный флаг на упаковке.

Влияние отдельных признаков (Feature Importance)

Рейтинговый анализ важности признаков (по результатам Ridge Regression и Random Forest):



Признак	Интерпретация влияния
base_price	Ключевой драйвер модели отражает исходную ценовую шкалу
price_per_100g	Нормализованный показатель стоимости учитывает разницу в весе и упаковке, усиливает сравнимость между категориями

category_мясо, category_сыры	Факторы, отражающие сегмент товара - мясо и сыры стабильно дороже.
weight	Масса упаковки положительно связана с итоговой ценой, но нелинейно (эффект оптовой скидки) - цена за 100 г при больших объемах снижается.
promo	Акции снижают цену, но эффект краткосрочный; если promo = 1 - модель прогнозирует на 5-10 сомов ниже.
store, packaging, brand, country	Незначительное отношение либо уже учтено косвенно через категорию, либо слабое влияние на восприятие цены покупателем.

Рынок демонстрирует функциональное ценообразование: конечная цена определяется объективными свойствами - вес, тип продукта, размер упаковки, а не символическими, вроде страны происхождения или бренда

Гипотеза 4:

Покупатели ориентируются прежде всего на сущность товара (что это и сколько граммов), а не на имиджевые маркеры (где произведено и какая марка). Это типично для продовольственного сегмента в экономиках с укорененным рациональным потреблением

Интерпретация:

Когда мы посмотрели, какие признаки сильнее всего влияют на цену, стало понятно, что решающую роль играют объективные характеристики товара, а не его марка или страна происхождения. Главным фактором в модели является base_price - базовая стоимость,

которая отражает исходную ценовую позицию товара в своей категории. Вторым важным показателем оказался `price_per_100g` - цена за 100 граммов. Этот признак помогает модели сравнивать продукты разных весов: например, литр молока и упаковку масла по цене на одинаковое количество граммов. Он показывает, сколько реально стоит товар при одинаковом объеме, и делает прогноз гораздо точнее

Категории тоже сильно влияют, особенно мясо и сыры, которые стабильно дороже других товарных групп. Это логично, производство таких продуктов сложнее и дороже, чем, например, круп или хлеба. Вес упаковки (`weight`) также имеет значение: чем больше товар, тем выше его общая цена, но интересный момент - зависимость не линейная. Большие упаковки обычно стоят дешевле за 100 граммов из-за эффекта оптовой скидки, когда крупные упаковки выгоднее

Признак `promo` (наличие скидки или акции) ожидаемо снижает цену. Когда в данных отмечено, что товар участвует в акции, модель прогнозирует цену на 5-10 сомов ниже. Это краткосрочный эффект, но он помогает учесть скидочные предложения

А вот такие признаки, как магазин (`store`), упаковка (`packaging`), бренд (`brand`) и страна (`country`) оказались незначимыми. Они либо уже косвенно связаны с категорией (например, мясные продукты чаще местного производства), либо просто не играют существенной роли в формировании цены

Все это говорит о том, что цены на рынке формируются по функциональному принципу: сколько весит, к какой категории относится, есть ли акция - вот что реально влияет на стоимость. Покупатели в Бишкеке в первую очередь смотрят на практические характеристики - что за товар и сколько он стоит за единицу веса, а не на то, где он сделан или какая у него торговая марка

Можно сказать, что поведение покупателей здесь в основном рациональное. Люди не переплачивают за имя бренда, они выбирают исходя из пользы, привычки и цены. Поэтому рынок продовольственных товаров показывает предсказуемую структуру: цена отражает свойства продукта, а не маркетинговые детали

Поведение моделей и метрики

1. Сравнение моделей регрессии

```
Regression model: Linear Regression
MAE: 11.107
RMSE: 22.727
R2: 0.975
CV R2 mean: 0.961

Regression model: Ridge Regression
MAE: 10.708
RMSE: 21.412
R2: 0.978
CV R2 mean: 0.971

Regression model: Random Forest Regressor
MAE: 10.714
RMSE: 27.136
R2: 0.964
CV R2 mean: 0.98

Regression model: Gradient Boosting Regressor
MAE: 9.407
RMSE: 26.405
R2: 0.966
CV R2 mean: 0.987
```

Модель	MAE (com)	RMSE (com)	R ²	CV R ² mean
Linear Regression	11.11	22.73	0.975	0.961
Ridge Regression	10.71	21.41	0.978	0.971

Random Forest	10.71	27.14	0.964	0.980
Gradient Boosting	9.41	26.41	0.966	0.987

Все модели показали высокие значения $R^2 > 0.96$, что говорит о том, что характеристики товара практически полностью объясняют его цену. Лучший баланс стабильности и точности достигает Ridge Regression - благодаря регуляризации она снижает влияние мультиколлинеарности (частичной взаимосвязанности признаков)

Ошибки:

- MAE примерно 10 сомов - в среднем модель ошибается на сумму не больше стоимости упаковки хлеба
- RMSE примерно 21 сом - демонстрирует невысокие амплитудные ошибки лишь для дорогих товаров.

Вывод: модель адекватно воспроизводит структуру цен, что позволяет использовать её не только для прогнозов, но и для оценки ценовых аномалий - товаров, явно выбивающихся из категориального диапазона

Интерпретация

Результаты сравнения моделей показали, что каждая из них предсказывает цены очень точно - показатель R^2 во всех случаях выше 0.96. Это означает, что модель объясняет почти все изменения цены через характеристики самого товара: вес, категорию, наличие акции, цену за 100 граммов и другие признаки. Проще говоря, данные достаточно качественные и хорошо отражают закономерности рынка - алгоритмы действительно понимают, от чего зависит стоимость продукта

Из всех протестированных вариантов самой надежной оказалась Ridge Regression - ее результат $R^2 = 0.978$, а средняя ошибка (MAE)

всего около 10 сомов. То есть модель в среднем ошибается на сумму, сравнимую со стоимостью булки хлеба, что очень точно для реальных цен. Ошибка RMSE примерно 21 сом показывает, что иногда отклонение немного больше, но в основном это касается дорогих товаров, где любая разница в цене в процентном отношении выглядит значимее

Преимущество Ridge Regression в том, что она использует регуляризацию - механизм, который помогает избежать переобучения и делает модель более устойчивой к пересекающимся признакам. Например, в данных вес и цена за 100 г взаимосвязаны, но благодаря регуляризации модель не путает их между собой

В целом, модель очень хорошо воспроизводит реальную структуру цен, она улавливает закономерности между характеристиками и стоимостью, при этом не переоценивает влияние случайных факторов. Это значит, что её можно применять не только для прогнозов цен на новые товары, но и для поиска аномалий, например, товаров, чья цена заметно отклоняется от типичной по категории. Такие случаи могут указывать на избыточную наценку, ценовую ошибку или наоборот, выгодное предложение

2. Сравнение моделей классификации

Модель	Accuracy	Precision	Recall	F1
Logistic Regression	0.932	0.934	0.932	0.932
Random Forest	0.989	0.989	0.989	0.989
Gradient Boosting	0.989	0.989	0.989	0.989

```
Classification model: Logistic Regression
Accuracy: 0.932
Precision: 0.934
Recall: 0.932
F1: 0.932

Classification model: Random Forest Classifier
Accuracy: 0.989
Precision: 0.989
Recall: 0.989
F1: 0.989

Classification model: Gradient Boosting Classifier
Accuracy: 0.989
Precision: 0.989
Recall: 0.989
F1: 0.989
```

Алгоритмы классификации великолепно разделили товары по уровню цены - бюджетный / средний / премиум. Высокие значения $F1 > 0.98$ означают почти полное совпадение предсказанных и реальных классов. Таким образом, ценовые сегменты имеют чёткие структурные основания и хорошо различаются признаками - модель не путает, например, крупу и сыр в ценовом смысле.

Гипотеза 5:

Можно автоматически распределять новые товары по ценовым категориям, даже без указания цены - только по описательным признакам. Это создает ценность для задач классификации ассортимента и мониторинга ценовых отклонений.

Интерпретация

Модели классификации показали очень высокий уровень точности - их средние показатели Accuracy, Precision, Recall и F1 около 0.99, что говорит о почти безошибочной работе. То есть алгоритмы практически всегда правильно определяют, к какому ценовому сегменту относится товар - бюджетному, среднему или премиальному. Фактически, совпадение между предсказанием модели и реальным классом продукта достигает 98-99%, а это уровень, близкий к идеальному.

Такой результат объясняется тем, что ценовые категории действительно сильно различаются по своим характеристикам: дешёвые товары имеют меньший вес, попроще упаковку, ограниченный набор брендов; средний сегмент - это товары повседневного спроса с более стабильным качеством и узнаваемыми брендами, премиальный уровень формируется за счёт дорогих категорий вроде сыров, мяса, кофе, импортных сладостей и деликатесов. Поэтому модель легко «разделяет» эти группы - она не путает, например, пачку гречки за 40 сомов с упаковкой сыра за 300 сомов.


Такое поведение модели показывает, что рынок имеет четко выраженную внутреннюю сегментацию, а признаки, используемые для описания товара, действительно отражают ценовой уровень. Из этого можно сделать практический вывод: даже если цена нового товара неизвестна, модель всё равно сможет определить его предполагаемый сегмент, опираясь только на характеристики - категорию, бренд, вес, упаковку, наличие акции и т.д.

Это открывает полезные возможности для аналитики супермаркета. С помощью такой модели можно автоматически распределять новые товары по ценовым группам, проверять, не выбивается ли товар из своей категории по цене, а также контролировать, правильно ли расставлены ценовые уровни внутри ассортимента. Так магазины могут поддерживать ценовой баланс и быстро находить несоответствия - например, если товар продаётся заметно дороже, чем другие из той же группы.

Диагностика модели

1. График «Predicted vs Actual Prices»

Почти точное совпадение предсказанных и фактических значений; лишь для товаров свыше 600 сомов возникает лёгкое недооценивание - нормально при редких значениях




Predicted vs Actual Prices - на нем почти все точки лежат близко к диагональной линии. Это значит, что модель предсказывает цену очень точно, когда товар реально стоит 100 сомов, модель выдает результат примерно 100 сомов. Только для самых дорогих товаров (свыше 600 сомов) появляется небольшая недооценка - модель иногда предсказывает чуть меньше, чем реальная цена. Это объясняется тем, что в данных мало таких дорогих примеров, и модель не успела на них научиться

2. Residuals Plot

Гипотеза 6:

Небольшие ошибки на дорогих товарах объясняются нехваткой наблюдений в этом диапазоне, при расширении выборки диапазон будет работать точнее



Residuals Plot, где показаны ошибки предсказаний (разница между реальной и предсказанной ценой). Точки на нём разбросаны хаотично - без какого-то направления вверх или вниз. Если бы модель систематически ошибалась, например, занижала дешёвые и завышала дорогие товары, то мы бы увидели наклон или определенную форму графика. А здесь ошибки идут в обе стороны случайно, что очень хороший знак. Большинство отклонений лежат в пределах плюс минус 30 сомов - это небольшой шум, показывающий нормальную естественную погрешность при работе с реальными ценами. Это

свойство говорит о стабильности и надежности модели - она не перекошена ни в одну сторону

Эти небольшие ошибки для дорогих товаров объясняются просто - их мало в выборке, поэтому модель не смогла увидеть достаточно примеров, чтобы выучить закономерность. Если добавить больше данных именно из этого сегмента, качество прогноза улучшится


3. Learning Curve

Обучающая точность (R^2 примерно 0.99) и валидационная (примерно 0.97-0.98) почти совпадают. Это признак отсутствия переобучения: модель не запомнила данные, а научилась общим закономерностям.

По мере увеличения обучающей выборки валидационная метрика растет, следовательно есть потенциал масштабирования

Гипотеза 7:

Добавление дополнительных магазинов (например, Фрунзе/Империя/Айчурок) позволит еще больше стабилизировать обобщенную модель рынка



Learning Curve или кривая обучения. На графике видно, что ошибки при обучении и на проверке почти одинаковые: R^2 примерно 0.99 на

обучающей выборке и около 0.97-0.98 на тестовой. Это значит, что модель не переобучилась - она не просто запомнила данные, а действительно поняла общие закономерности между признаками и ценой. Это именно то, чего добиваются при построении хорошей модели. Кроме того, кривая обучения показывает ещё одну вещь: если увеличить объем данных (например, включить другие супермаркеты - «Фрунзе», «Империя», «Айчурок»), качество прогнозов может даже немного повыситься. То есть модель обладает потенциалом к масштабированию - она устойчива и сможет адаптироваться к новым данным без потери точности.

Социально-экономическое толкование

Анализ показал, что цены в бишкекских супермаркетах формируются рационально - не из-за бренда или происхождения, а из-за вполне конкретных свойств товара: его веса, категории, состава и упаковки. Это значит, что на рынке действует логика

цена = качество + себестоимость

Такое ценообразование типично для стран с развивающейся экономикой, где люди делают покупки, исходя из практических потребностей, а не из желания подчеркнуть статус

Также можно сказать, что рынок Бишкека зрелый и конкурентный. Средние цены в Globus и Narodny почти одинаковые, хотя иногда в Globus немного выше. Разница около 20 % не является статистически значимой - на деле это значит, что обе сети следят за конкурентами и держат цены в одном диапазоне. Вероятно, у них схожие поставщики и общая логистика, что приводит к выровненной структуре цен

Интересно, что импортные товары не оказываются дороже. Наоборот, они часто попадают в более дешевый сегмент, потому что зарубежные поставки хорошо налажены, а логистика не создает больших надбавок. Зато местные товары, особенно мясо и молочные продукты, стоят дороже. Это объясняется тем, что свежие продукты требуют быстрых поставок и хранения, что делает их производство дороже

В целом такая картина показывает, рынок сбалансирован, цены прозрачны, а покупатели выбирают в первую очередь по качеству и необходимости, а не по «имени» страны или торговой марки

Общие итоги исследования

- Ответ на вопрос проекта:
Да, цену товара в супермаркетах Бишкека можно предсказать с высокой достоверностью (R^2 примерно 0.98)
- Главные факторы:
Базовая цена, категория, вес и нормализованная стоимость (price_per_100g)
- Неопределяющие факторы:
Страна, бренд, тип упаковки
- Качество модели:
Ridge Regression - лучшее соотношение точности и устойчивости, MAE примерно 10 сомов.
- Классификация:
Random Forest Classifier почти без ошибок определяет ценовой сегмент
- Вывод для практики:
Модель может использоваться для прогнозирования новых цен, проверки корректности установленных, определения целевых ценовых диапазонов для новых товаров и оптимизации промополитики

Результаты исследования показали, что цену товара в супермаркетах Бишкека действительно можно предсказать очень точно - модель объясняет около 98 % всех различий между ценами.

Это значит, что ценовая структура рынка понятна и хорошо описывается данными. Наибольшее влияние на цену оказывают основные характеристики товара - его базовая стоимость, категория, вес и рассчитанная цена за 100 граммов. А вот такие признаки, как страна производства, бренд или тип упаковки, почти не влияют на итоговую цену.

Лучше всего показала себя модель Ridge Regression, которая даёт точные и устойчивые результаты: средняя ошибка около 10 сомов - очень мало по сравнению с реальными ценами. Для классификации по уровням (бюджетный, средний, премиум) почти безошибочно работает Random Forest Classifier. Практически эта модель может использоваться магазинами, чтобы автоматически прогнозировать цены на новые товары, проверять, не завышены ли действующие, анализировать ценообразование по категориям и управлять скидками или промоакциями более эффективно

B1. Разница цен между магазинами Globus и Narodny

Средняя цена товаров в Globus составила 118.6 сомов, а в Narodny - 99 сомов, то есть примерно на 20 % дешевле. При этом почти во всех категориях (мясо, сыры, молочные продукты, кондитерка) товары в Globus немного дороже. Однако t-тест ($p = 0.06$) показал, что разница статистически незначима, то есть она может быть случайной. Скорее всего, Globus просто предлагает больше брендованных и фасованных товаров

Вывод: уровень цен в магазинах близкий - рынок конкурентный, без явного лидера по дороговизне.

B2. Импортные и местные товары

Средняя цена кыргызских товаров - 132.7 сомов, а импортных (из Казахстана, России, Украины, Италии) от 60 до 95 сомов. Гипотеза "импортное дороже" не подтвердилась: местные продукты, особенно

мясо и молочные, оказались самыми дорогими. Это объясняется тем, что такие категории сами по себе имеют высокую себестоимость.

Вывод: цена зависит не от страны, а от типа товара - страна производства не играет решающей роли.

V3. Влияние признака `price_per_100g`

Признак `price_per_100g` помогает сравнивать товары разных весов. После его добавления качество модели улучшилось: R^2 поднялся примерно до 0.978. Модель стала лучше понимать, как вес влияет на цену, и точнее предсказывать итоговую стоимость.

Вывод: добавление `price_per_100g` заметно повысило точность, сделав прогнозы более реалистичными.

V4. Технический эффект от One-Hot Encoding

Метод One-Hot Encoding преобразует категориальные признаки (например, категория, бренд, страна, упаковка, магазин) в числовой формат, чтобы их можно было использовать в моделях машинного обучения. Для каждой категории создаётся отдельный столбец с 0 или 1, показывающий наличие этого признака. После кодирования размер таблицы увеличивается - например, если было 15 категорий, появится 15 новых колонок. Это делает данные более подробными и понятными для алгоритма, теперь он может корректно учитывать различия между категориями без искажений. Такой подход улучшает способность модели находить взаимосвязи, потому что вместо одного текстового признака категория появляется множество бинарных характеристик. В результате модель понимает, что продукты из разных категорий могут иметь разную типичную цену, даже если другие параметры одинаковы.

Вывод: One-Hot Encoding позволил перевести категориальные данные в форму, понятную модели, увеличив точность прогнозов и стабильность обучения.

V5. Анализ кривой обучения (Learning Curve)

На графике кривой обучения видно, что качество на обучающей выборке (R^2 примерно 0.99) и на валидационной (R^2 примерно 0.97-0.98) почти одинаково. Это говорит о том, что модель не

переобучилась - она запомнила данные и действительно научилась распознавать закономерности. К тому же по мере увеличения количества данных кривая валидации немного растёт. Это значит, что если собрать больше товаров (включить, например, данные из других магазинов вроде Фрунзе или Айчурок), модель сможет стать ещё точнее и устойчивее. Сейчас её качество уже очень высокое, и для практических задач данных достаточно, но расширение выборки улучшит обобщающую способность, особенно для дорогих категорий, где примеров пока немного.

Вывод: модель показала отличную обучаемость и стабильность. Ей не требуется срочное увеличение данных, но при добавлении новых наблюдений качество прогнозов может стать еще выше.

Заключительная мысль

В целом исследование показывает, что цены на продукты в Бишкеке формируются честно и предсказуемо. Стоимость зависит прежде всего от свойств товара - его категории, веса и состава, а не от бренда или страны. Это значит, что рынок достаточно зрелый и стабильный, а различия в ценах чаще связаны с ассортиментом, а не с искусственными наценками.

Такой рынок можно назвать прозрачным и рациональным, люди покупают по потребности, а не по престижу марки. Поэтому методы машинного обучения здесь полезны не только для точного прогнозирования цен, но и для понимания общей структуры экономики и поведения рынка - они помогают увидеть, как устроена система ценообразования на уровне целых торговых сетей